NetApp 하이브리드 클라우드 데이터 솔루션 - 고객 사용 사례를 기반으로 Spark 및 Hadoop

NetApp Solutions

NetApp
June 20, 2022

This PDF was generated from https://docs.netapp.com/ko-kr/netapp-solutions/data-analytics/hdcs-sh-solution-overview.html on June 20, 2022. Always check docs.netapp.com for the latest.

목차

NetApp 하이브리드 클라우드 데이터 솔루션 - 고객 사용 사례를 기반으로 Spark 및 Hadoop . . . 1
TR-4657: NetApp 하이브리드 클라우드 데이터 솔루션 - 고객 사용 사례를 기반으로 Spark 및 Hadoop . . . 1
NetApp에서 제공하는 빅데이터 아키텍처 관련 Data Fabric . . . 2
Hadoop 데이터 보호 및 NetApp . . . 6
Hadoop 데이터 보호 활용 사례 개요 . . . 6
사용 사례 1: Hadoop 데이터 백업 . . . 7
사용 사례 2: 클라우드에서 사내로 백업 및 재해 복구 . . . 11
사용 사례 3: 기존 Hadoop 데이터에 대해 DevTest 활성화 . . . 13
사용 사례 4: 데이터 보호 및 멀티 클라우드 연결 . . . 14
사용 사례 5: 분석 워크로드 가속화 . . . 16
결론 . . . 17

NetApp 하이브리드 클라우드 데이터 솔루션 - 고객 사용 사례를 기반으로 Spark 및 Hadoop

TR-4657: NetApp 하이브리드 클라우드 데이터 솔루션 - 고객 사용 사례를 기반으로 Spark 및 Hadoop

NetApp의 Karthikeyan Nagalingam 및 Sathish Thyagarajan

본 문서는 NetApp AFF 및 FAS 스토리지 시스템, NetApp Cloud Volumes ONTAP, NetApp 연결형 스토리지, Spark 및 Hadoop용 NetApp FlexClone 기술을 사용하는 하이브리드 클라우드 데이터 솔루션에 대해 설명합니다. 이러한 솔루션 아키텍처를 통해 고객은 자신의 환경에 적합한 데이터 보호 솔루션을 선택할 수 있습니다. NetApp은 고객과의 상호 작용 및 비즈니스 사용 사례를 기반으로 이러한 솔루션을 설계했습니다. 이 문서에서는 다음과 같은 자세한 정보를 제공합니다.

- Spark 및 Hadoop 환경 및 고객의 당면 과제를 해결하기 위해 데이터 보호가 필요한 이유
- NetApp 비전 및 구성 요소와 서비스를 기반으로 하는 Data Fabric
- 이러한 구성 요소를 사용하여 유연한 데이터 보호 워크플로우를 구축하는 방법
- 실제 고객 사용 사례를 기반으로 한 여러 아키텍처의 장단점을 설명합니다. 각 활용 사례는 다음과 같은 구성 요소를 제공합니다.
  - 고객 시나리오
  - 요구사항 및 당면 과제
  - 해결하세요
  - 솔루션 요약

Hadoop 데이터 보호를 선택해야 하는 이유

Hadoop 및 Spark 환경에서는 다음과 같은 문제를 해결해야 합니다.

- * 소프트웨어 또는 사용자 오류. * Hadoop 데이터 작업을 수행하는 동안 소프트웨어 업데이트에 사람의 실수가 발생할 수 있으며, 이로 인해 작업에 예상치 못한 결과가 발생할 수 있습니다. 이 경우 오류나 부당한 결과를 방지하려면 데이터를 보호해야 합니다. 예를 들어, 소프트웨어 업데이트가 제대로 실행되지 않아 트래픽 신호 데이터를 일반 텍스트 형식으로 제대로 분석하지 못하는 새로운 기능이 추가되었습니다. 이 소프트웨어는 JSON 및 기타 비 텍스트 파일 형식을 분석하여 실시간 트래픽 제어 분석 시스템을 통해 데이터 포인트가 누락된 예측 결과를 생성합니다. 이 상황은 출력 결함을 초래하여 교통 신호에서 사고를 일으킬 수 있습니다. 데이터 보호는 이전 작업 중인 응용 프로그램 버전으로 빠르게 롤백할 수 있는 기능을 제공하여 이 문제를 해결할 수 있습니다.
- * 규모와 확장성 * 데이터 소스와 볼륨의 수가 계속 증가함에 따라 분석 데이터의 크기가 매일 증가하고 있습니다. 소셜 미디어, 모바일 앱, 데이터 분석 및 클라우드 컴퓨팅 플랫폼은 현재 빅데이터 시장의 주요 데이터 소스로서 빠르게 증가하고 있으며, 따라서 정확한 데이터 운영을 위해 데이터를 보호해야 합니다.
- * Hadoop의 기본 데이터 보호. * Hadoop에는 데이터를 보호하는 기본 명령이 있지만 이 명령은 백업 중에 데이터의 일관성을 제공하지 않습니다. 디렉토리 레벨 백업만 지원합니다. Hadoop에서 생성된 스냅샷은 읽기 전용이며 백업 데이터를 직접 재사용하는 데 사용할 수 없습니다.

Hadoop 및 Spark 고객의 데이터 보호 당면 과제

Hadoop 및 Spark 고객의 일반적인 과제는 데이터 보호 중에 운영 클러스터의 성능에 부정적인 영향을 주지 않고 백업 시간을 단축하고 백업 안정성을 높이는 것입니다.

또한 고객은 RPO(복구 시점 목표) 및 RTO(복구 시간 목표) 다운타임을 최소화하고 사내 및 클라우드 기반 재해 복구 사이트를 제어하여 비즈니스 연속성을 최적화해야 합니다. 이 제어 기능은 일반적으로 엔터프라이즈급 관리 툴을 사용하는 데서 비롯됩니다.

Hadoop과 Spark 환경은 데이터 볼륨이 엄청나며 증가하기 때문에 복잡합니다. 하지만 데이터가 도착하는 속도는 점점 증가하고 있습니다. 이 시나리오를 통해 소스 데이터에서 효율적인 최신 DevTest 및 QA 환경을 빠르게 생성하기가 어렵습니다. NetApp은 이러한 과제를 인식하고 이 백서에 제공된 솔루션을 제공합니다.

"다음 단계로: NetApp에서 제공하는 빅데이터 아키텍처 관련 Data Fabric"

NetApp에서 제공하는 빅데이터 아키텍처 관련 Data Fabric

"이전: 솔루션 개요"

NetApp이 제공하는 Data Fabric은 클라우드 및 사내 환경에서 데이터 관리를 단순화하고 통합하여 디지털 전환을 가속합니다.

NetApp이 제공하는 Data Fabric은 데이터 가시성과 통찰력, 데이터 액세스 및 제어, 데이터 보호 및 보안을 위한 일관성 있는 통합 데이터 관리 서비스 및 애플리케이션(구성 요소)을 제공합니다(아래 그림 참조).

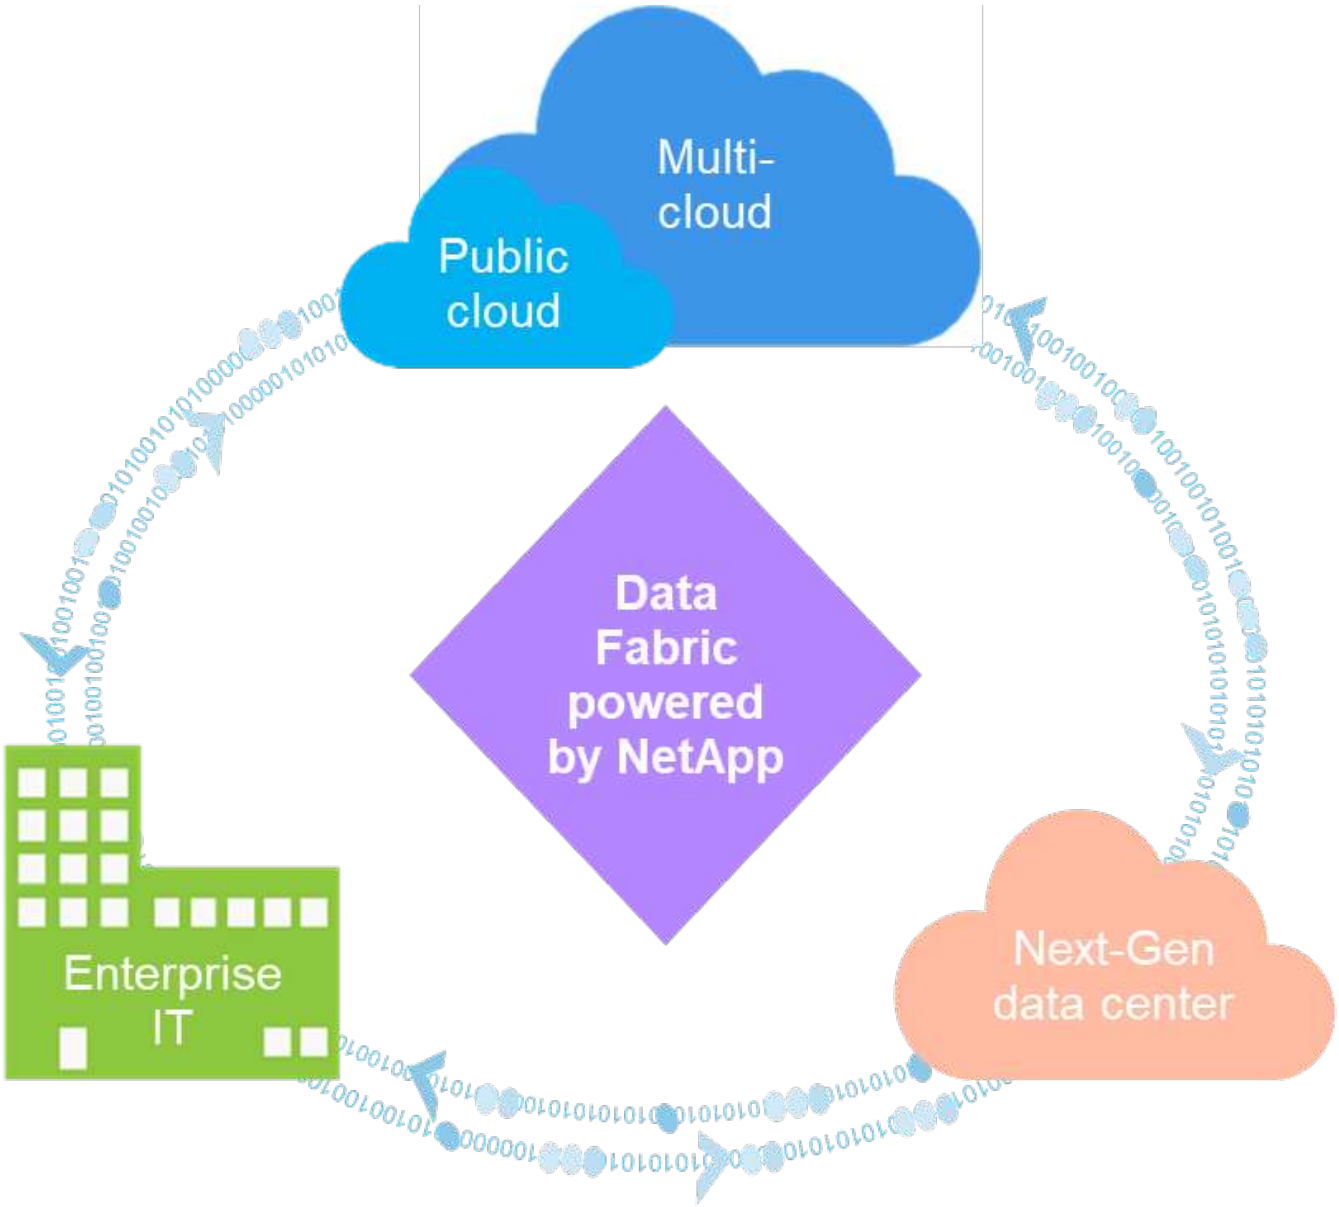

검증된 **Data Fabric** 고객 사용 사례

NetApp이 제공하는 Data Fabric은 고객에게 다음과 같은 9가지 검증된 사용 사례를 제공합니다.

- 분석 워크로드 가속화
- DevOps 혁신 가속
- 클라우드 호스팅 인프라 구축
- 클라우드 데이터 서비스 통합
- 데이터 보호 및 보안
- 비정형데이터의 최적화
- 데이터 센터의 효율성 확보
- 데이터 통찰력 및 제어 제공
- 단순화 및 자동화

본 문서는 9가지 사용 사례 중 2가지(솔루션 포함)를 다룹니다.

- 분석 워크로드 가속화
- 데이터 보호 및 보안

NetApp NFS 직접 액세스

아래 그림에 표시된 NetApp NFS 직접 액세스(이전의 NetApp In-Place Analytics Module)를 사용하면 데이터를 이동하거나 복사하지 않고도 기존 또는 새로운 NFSv3 또는 NFSv4 데이터에 대해 빅데이터 분석 작업을 실행할 수 있습니다. 여러 데이터 복제본을 방지하고 소스와 데이터를 동기화할 필요가 없습니다. 예를 들어 금융 부문에서 데이터를 한 위치에서 다른 위치로 이동하는 것은 쉬운 일이 아닌 법적 의무를 준수해야 합니다. 이 시나리오에서는 NetApp NFS 직접 액세스가 원래의 위치에서 재무 데이터를 분석합니다. 또 다른 주요 이점은 NetApp NFS 직접 액세스를 사용하여 기본 Hadoop 명령을 사용하여 Hadoop 데이터를 간편하게 보호하고 NetApp의 강력한 데이터 관리 포트폴리오를 활용하여 데이터 보호 워크플로우를 활성화할 수 있다는 것입니다.

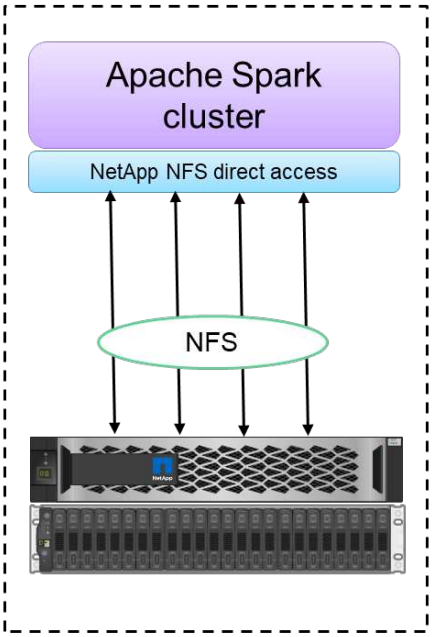

Configuration 1: NFS as primary storage

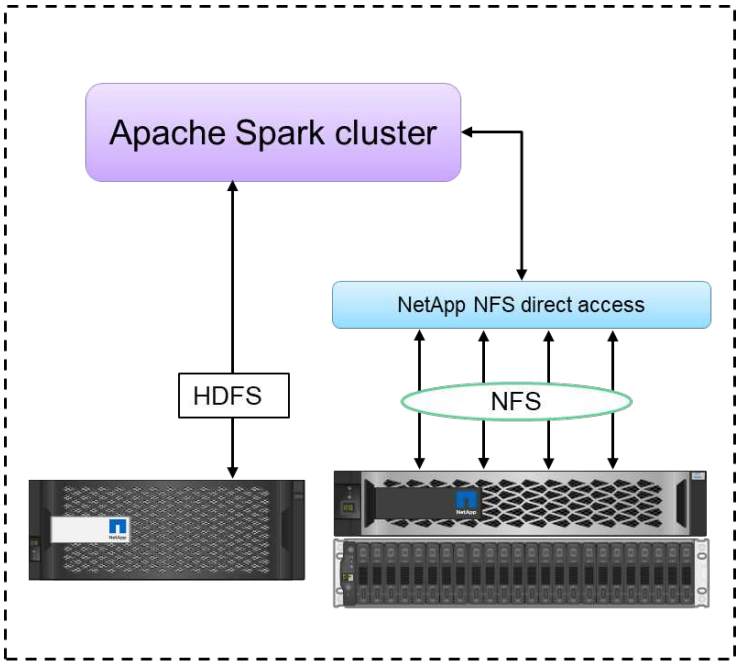

Configuration 2: HDFS and NFS in single Spark cluster

NetApp NFS 직접 액세스에서는 Hadoop/Spark 클러스터에 다음과 같은 두 가지 유형의 구축 옵션을 제공합니다.

- 기본적으로 Hadoop/Spark 클러스터는 데이터 스토리지와 기본 파일 시스템에 HDFS(Hadoop Distributed File System)를 사용합니다. NetApp NFS 직접 액세스는 기본 HDFS를 NFS 스토리지로 대체하여 NFS 데이터에 대한 직접 분석 작업을 지원합니다.
- 다른 구축 옵션에서 NetApp NFS 직접 액세스는 NFS를 단일 Hadoop/Spark 클러스터의 HDFS와 함께 추가 스토리지로 구성할 수 있도록 지원합니다. 이 경우 고객은 NFS 내보내기를 통해 데이터를 공유하고 HDFS 데이터와 함께 동일한 클러스터에서 데이터를 액세스할 수 있습니다.

NetApp NFS 직접 액세스를 사용할 때의 주요 이점은 다음과 같습니다.

- 현재 위치의 데이터를 분석하여 분석 데이터를 HDFS와 같은 Hadoop 인프라스트럭처로 이동하는 데 시간과 성능이 많이 소모되는 작업을 방지합니다.
- 복제본 수를 3개부터 1개로 줄입니다.

- 사용자가 컴퓨팅 및 스토리지를 분리하여 독립적으로 확장할 수 있습니다.
- ONTAP의 강력한 데이터 관리 기능을 활용하여 엔터프라이즈 데이터 보호 기능을 제공합니다.
- Hortonworks 데이터 플랫폼에서 인증되었습니다.
- 하이브리드 데이터 분석을 구축할 수 있습니다.
- 동적 다중 스레드 기능을 활용하여 백업 시간을 단축합니다.

빅 데이터를 위한 구성 요소

NetApp 기반의 Data Fabric은 아래 그림과 같이 데이터 액세스, 제어, 보호 및 보안을 위한 데이터 관리 서비스와 애플리케이션(구성 요소)을 통합합니다.

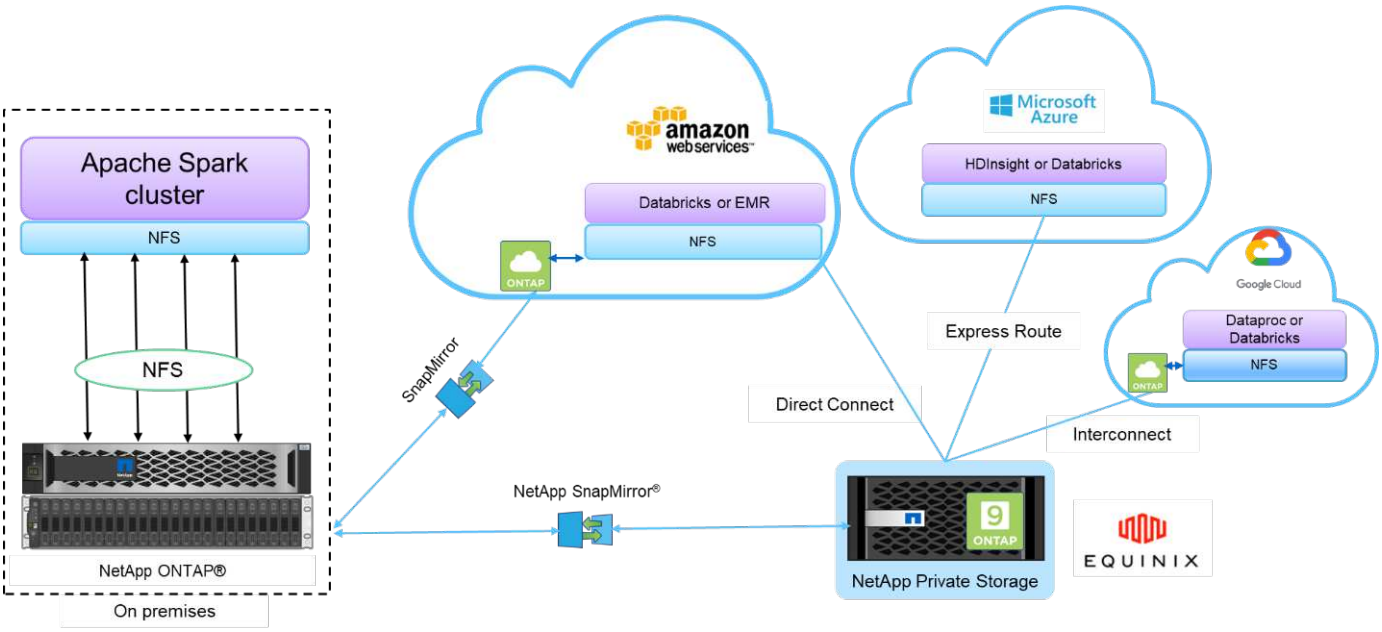

위 그림의 구성 요소는 다음과 같습니다.

- * NetApp NFS 직접 액세스 * 는 추가 소프트웨어 또는 드라이버 요구사항 없이 최신 Hadoop 및 Spark 클러스터를 NetApp NFS 볼륨에 직접 액세스할 수 있도록 지원합니다.
- * NetApp Cloud Volumes ONTAP 및 클라우드 볼륨 서비스. * Microsoft Azure 클라우드 서비스의 AWS(Amazon Web Services) 또는 ANF(Azure NetApp Files)에서 실행되는 ONTAP를 기반으로 하는 소프트웨어 정의 연결형 스토리지.
- NetApp SnapMirror 기술 *. 사내 및 ONTAP 클라우드 또는 NPS 인스턴스 간에 데이터 보호 기능을 제공합니다.
- * 클라우드 서비스 공급자 * 이러한 공급자에는 AWS, Microsoft Azure, Google Cloud 및 IBM Cloud가 포함됩니다.
- * PaaS. * AWS의 EMR(Amazon Elastic MapReduce) 및 Databricks와 같은 클라우드 기반 분석 서비스와 Microsoft Azure HDInsight 및 Azure Databricks

"이제 Hadoop 데이터 보호와 NetApp이 모두 필요합니다."

Hadoop 데이터 보호 및 NetApp

"이전: NetApp의 빅데이터 아키텍처 기반 Data Fabric"

Hadoop DistCp는 대규모 클러스터 간 및 클러스터 간 복제에 사용되는 기본 툴입니다. 아래 그림에 표시된 Hadoop DistCp 기본 프로세스는 MapReduce와 같은 Hadoop 기본 툴을 사용하여 HDFS 소스에서 해당 타겟으로 Hadoop 데이터를 복제하는 일반적인 백업 워크플로우입니다. NetApp NFS 직접 액세스를 통해 고객은 NFS를 Hadoop DistCp 툴의 타겟 타겟으로 설정하여 MapReduce를 통해 HDFS 소스에서 NFS 공유로 데이터를 복사할 수 있습니다. NetApp NFS 직접 액세스는 DistCp 툴을 위한 NFS 드라이버 역할을 합니다.

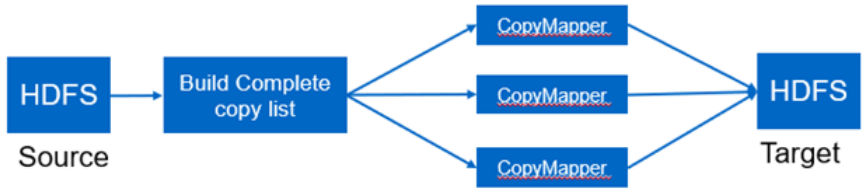

Hadoop Distcp Basic Process

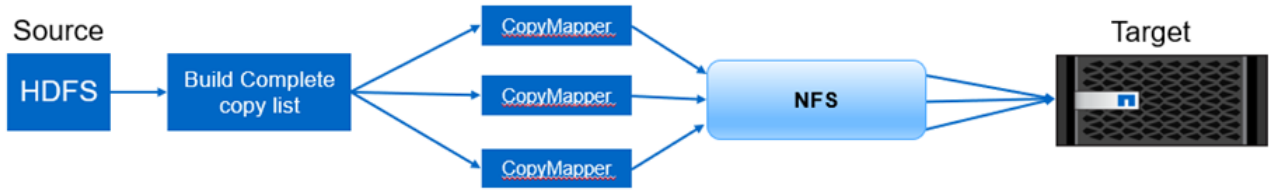

Hadoop Distcp and NetApp

"다음: Hadoop 데이터 보호 활용 사례 개요"

Hadoop 데이터 보호 활용 사례 개요

"이전: Hadoop 데이터 보호 및 NetApp"

이 섹션에서는 이 백서의 초점을 구성하는 데이터 보호 활용 사례에 대해 자세히 설명합니다. 나머지 섹션에서는 고객 문제(시나리오), 요구 사항 및 당면 과제, 솔루션 등 각 사용 사례에 대한 자세한 정보를 제공합니다.

사용 사례 1: Hadoop 데이터 백업

이 활용 사례에서 In-Place Analytics Module은 대형 금융 기관에서 긴 백업 시간을 24시간 이상으로 단축하면서 몇 시간 미만으로 단축하도록 지원했습니다.

사용 사례 2: 클라우드에서 사내로 백업 및 재해 복구

NetApp에서 제공하는 Data Fabric을 구성 요소로 사용함으로써 대규모 브로드캐스트 회사는 주문형, 즉각적인 데이터 전송 같은 다양한 데이터 전송 모드에 따라 클라우드 데이터를 사내 데이터 센터에 백업하는 요구사항을 충족시킬 수 있었습니다. 또는 Hadoop/Spark 클러스터 로드를 기반으로 합니다.

사용 사례 3: 기존 Hadoop 데이터에 대해 DevTest 활성화

NetApp 솔루션을 통해 온라인 음악 유통업체는 다양한 지점에서 공간 효율적인 다중 Hadoop 클러스터를 신속하게 구축하여 보고서를 생성하고 예약된 정책을 사용하여 일일 DevTest 작업을 실행할 수 있었습니다.

사용 사례 4: 데이터 보호 및 멀티 클라우드 연결

한 대형 서비스 공급자는 NetApp이 제공하는 Data Fabric을 사용하여 다양한 클라우드 인스턴스에서 고객에게 멀티 클라우드 분석을 제공합니다.

사용 사례 5: 분석 워크로드 가속화

가장 큰 금융 서비스 및 투자 은행 중 하나는 NetApp 네트워크 연결 스토리지 솔루션을 사용하여 I/O 대기 시간을 줄이고 정량 재무 분석 플랫폼을 가속화했습니다.

"다음: 활용 사례 1 - Hadoop 데이터 백업"

사용 사례 1: Hadoop 데이터 백업

"이전: Hadoop 데이터 보호 활용 사례 개요"

시나리오

이 시나리오에서는 고객이 대규모 사내 Hadoop 저장소를 보유하고 있으며 재해 복구를 위해 백업하려고 합니다. 그러나 고객의 현재 백업 솔루션은 비용이 많이 들고 24시간 이상의 긴 백업 윈도우에 어려움을 겪고 있습니다.

요구사항 및 당면 과제

이 사용 사례의 주요 요구사항과 과제는 다음과 같습니다.

- 소프트웨어 하위 호환성:
  - 제안된 대체 백업 솔루션은 운영 Hadoop 클러스터에 사용되는 현재 실행 중인 소프트웨어 버전과 호환되어야 합니다.
- 확정된 SLA를 충족하기 위해 제안된 대체 솔루션은 매우 낮은 RPO 및 RTO를 달성해야 합니다.
- NetApp 백업 솔루션을 통해 생성된 백업은 데이터 센터에서 로컬로 구축된 Hadoop 클러스터뿐만 아니라 원격 사이트의 재해 복구 위치에서 실행되는 Hadoop 클러스터에서도 사용할 수 있습니다.
- 제안된 솔루션은 비용 효율적이어야 합니다.
- 제안 솔루션은 백업 시간 동안 현재 실행 중인 운영 중인 분석 작업의 성능 영향을 줄여야 합니다.

고객의 기존 백업 솔루션

아래 그림은 원래 Hadoop 네이티브 백업 솔루션을 보여 줍니다.

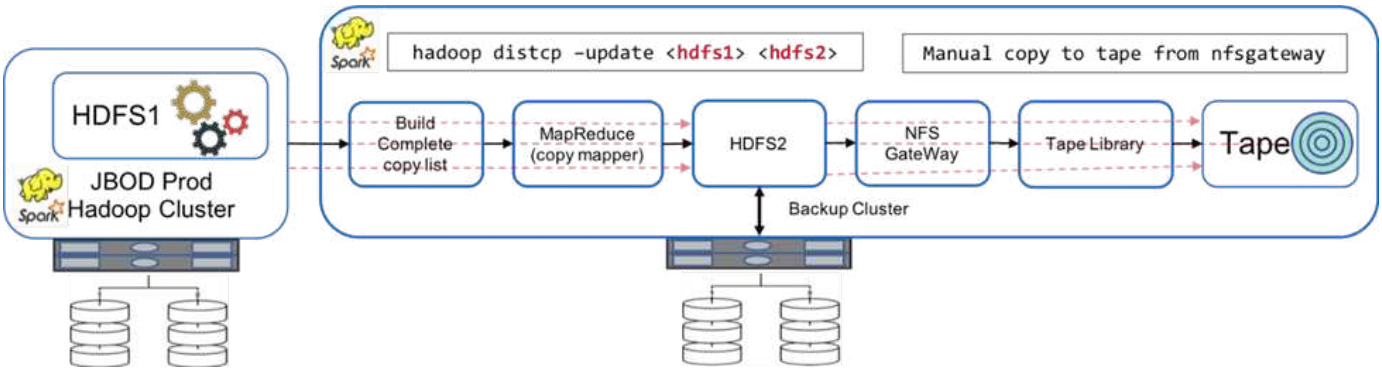

운영 데이터는 중간 백업 클러스터를 통해 테이프로 보호됩니다.

- HDFS1 데이터는 'Hadoop distcp-update<hdfs1><hdfs2>' 명령을 실행하여 HDFS2에 복사됩니다.
- 백업 클러스터는 NFS 게이트웨이 역할을 하며 테이프 라이브러리를 통해 Linux 'CP' 명령을 통해 테이프에 데이터를 수동으로 복사합니다.

원래 Hadoop 네이티브 백업 솔루션의 이점은 다음과 같습니다.

- 이 솔루션은 Hadoop 기본 명령을 기반으로 하므로 사용자가 새로운 절차를 배울 필요가 없습니다.
- 이 솔루션은 업계 표준 아키텍처와 하드웨어를 활용합니다.

원래 Hadoop 네이티브 백업 솔루션의 단점은 다음과 같습니다.

- 긴 백업 시간이 24시간을 초과하므로 운영 데이터가 취약해집니다.
- 백업 시간 동안 클러스터 성능이 크게 저하되었습니다.
- 테이프에 복사하는 것은 수동 프로세스입니다.
- 백업 솔루션은 필요한 하드웨어 및 수동 프로세스에 필요한 인력 시간의 측면에서 비용이 많이 듭니다.

백업 솔루션

이러한 당면 과제와 요구 사항을 바탕으로 기존 백업 시스템을 고려하여 세 가지 가능한 백업 솔루션을 제안하였습니다. 다음 하위 섹션에서는 이러한 세 가지 백업 솔루션 각각에 대해 설명합니다. 솔루션 A에서 솔루션 C까지의 레이블이 지정되어 있습니다

솔루션 **A**

솔루션 A는 아래 그림과 같이 데이터 이동 없는 분석 모듈을 백업 Hadoop 클러스터에 추가하여 NetApp NFS 스토리지 시스템에 대한 보조 백업을 허용함으로써 테이프 요구 사항을 제거합니다.

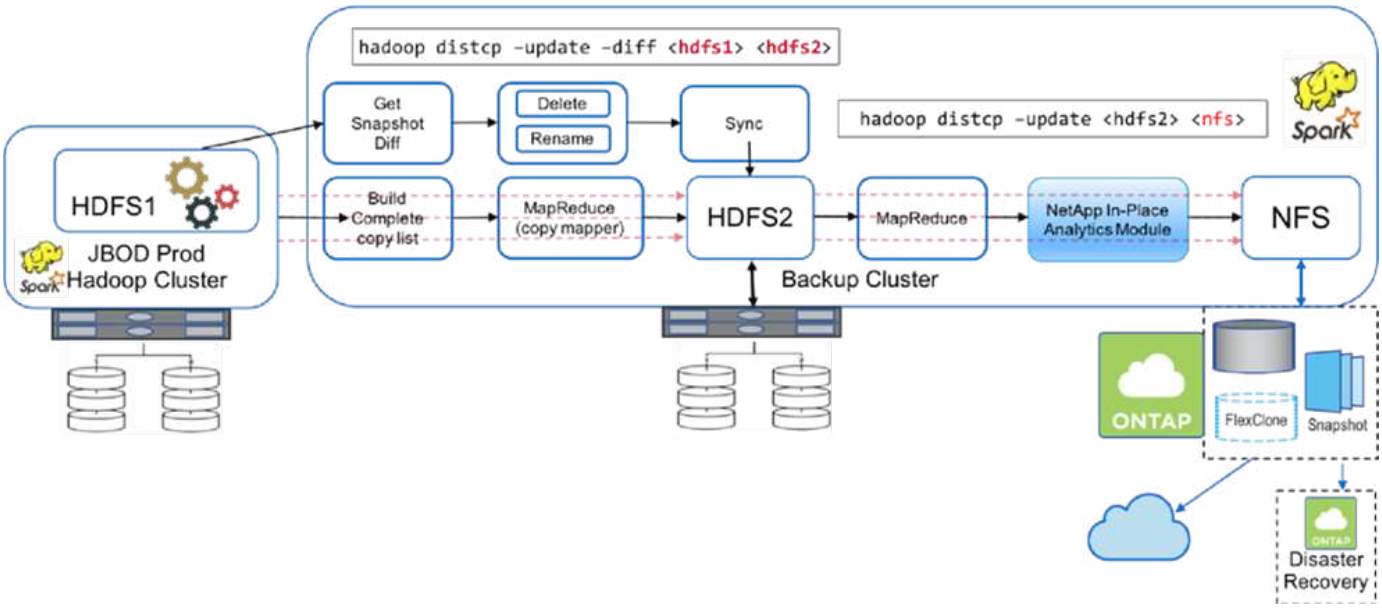

솔루션 A에 대한 자세한 작업은 다음과 같습니다.

- 운영 Hadoop 클러스터에는 보호가 필요한 HDFS에 고객의 분석 데이터가 있습니다.
- HDFS가 포함된 백업 Hadoop 클러스터는 데이터의 중간 위치로 작동합니다. JBOD(Just a Bunch of Disks)는 운영 및 백업 Hadoop 클러스터 모두에서 HDFS용 스토리지를 제공합니다.
- Hadoop distcp –update –diff <hdfs1><hdfs2>' 명령을 실행하여 운영 클러스터 HDFS에서 백업 클러스터 HDFS로 Hadoop 운영 데이터를 보호합니다.

> Hadoop 스냅샷은 운영 환경에서 백업 Hadoop 클러스터로 데이터를 보호하는 데 사용됩니다.

- NetApp ONTAP 스토리지 컨트롤러는 NFS로 내보낸 볼륨을 제공하며 백업 Hadoop 클러스터에 프로비저닝됩니다.
- MapReduce와 여러 개의 mapper를 활용하는 "Hadoop distcp" 명령을 실행하면 데이터 이동 없는 분석 모듈을 사용하여 분석 데이터가 백업 Hadoop 클러스터에서 NFS로 보호됩니다.

  NetApp 스토리지 시스템의 NFS에 데이터가 저장된 후 NetApp Snapshot, SnapRestore 및 FlexClone 기술을 사용하여 필요에 따라 Hadoop 데이터를 백업, 복원, 복제할 수 있습니다.

> SnapMirror 기술을 사용하여 Hadoop 데이터를 클라우드뿐 아니라 재해 복구 위치에도 보호할 수 있습니다.

솔루션 A의 이점은 다음과 같습니다.

- Hadoop 운영 데이터는 백업 클러스터로부터 보호됩니다.
- HDFS 데이터는 NFS를 통해 보호되므로 클라우드 및 재해 복구 위치에 대한 보호가 가능합니다.
- 백업 작업을 백업 클러스터로 오프로드하여 성능을 향상시킵니다.
- 수동 테이프 작업이 필요 없습니다
- NetApp 툴을 통해 엔터프라이즈 관리 기능을 지원합니다.
- 기존 환경을 최소한으로 변경해야 합니다.

- 비용 효율적인 솔루션입니다.

이 솔루션의 단점은 성능을 향상시키기 위해 백업 클러스터와 추가 매퍼가 필요하다는 것입니다.

이 고객은 단순성, 비용, 전반적인 성능 때문에 최근에 솔루션 A를 배포했습니다.

이 솔루션에서는 JBOD 대신 ONTAP의 SAN 디스크를 사용할 수 있습니다. 이 옵션은 백업 클러스터 스토리지 로드를 ONTAP로 오프로드하지만, 단점은 SAN 패브릭 스위치가 필요하다는 점입니다.

해결 방법 **B**

솔루션 B는 운영 Hadoop 클러스터에 데이터 이동 없는 분석 모듈을 추가하여 아래 그림과 같이 백업 Hadoop 클러스터가 필요하지 않습니다.

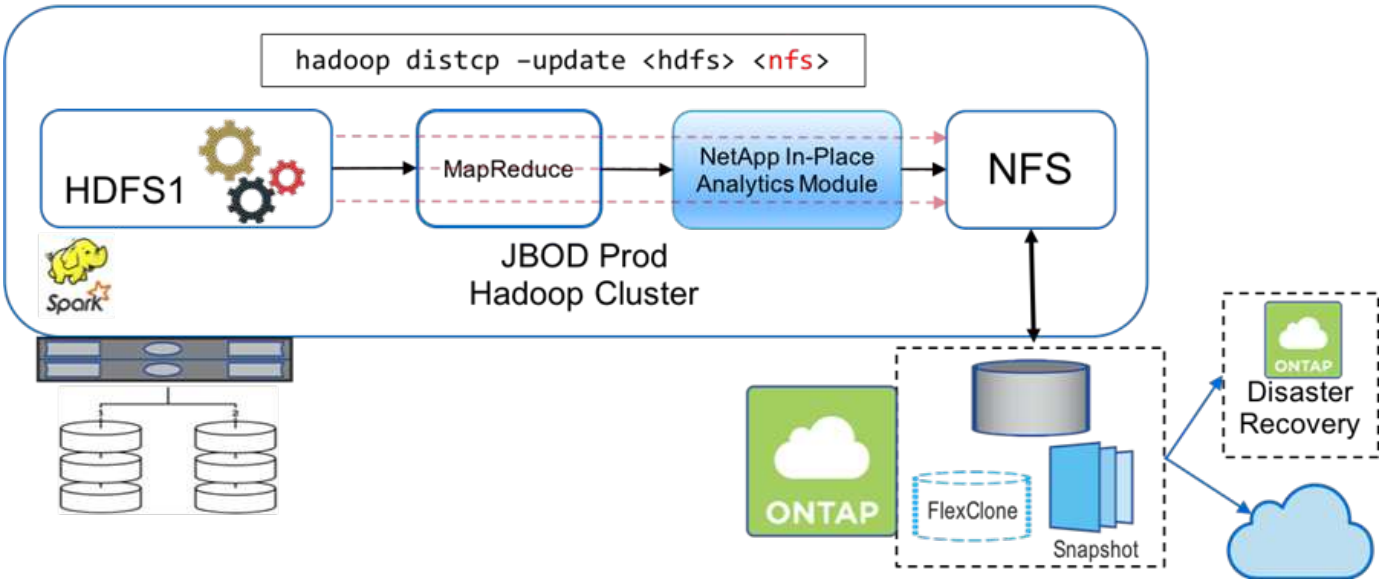

솔루션 B에 대한 자세한 작업은 다음과 같습니다.

- NetApp ONTAP 스토리지 컨트롤러는 운영 Hadoop 클러스터에 NFS 내보내기를 프로비저닝합니다.

  Hadoop 네이티브 'Hadoop distcp' 명령은 Hadoop 데이터를 데이터 이동 없는 분석 모듈을 통해 운영 클러스터 HDFS에서 NFS로 보호합니다.

- NetApp 스토리지 시스템의 NFS에 데이터가 저장된 후에는 Snapshot, SnapRestore 및 FlexClone 기술을 사용하여 필요에 따라 Hadoop 데이터를 백업, 복원, 복제할 수 있습니다.

솔루션 B의 이점은 다음과 같습니다.

- 운영 클러스터는 백업 솔루션에 맞게 약간 수정되어 구축이 간소화되고 추가 인프라스트럭처 비용이 절감됩니다.
- 백업 작업을 위한 백업 클러스터는 필요하지 않습니다.
- HDFS 운영 데이터는 NFS 데이터 변환 시 보호됩니다.
- 이 솔루션을 사용하면 NetApp 툴을 통해 엔터프라이즈 관리 기능을 수행할 수 있습니다.

이 솔루션의 단점은 프로덕션 클러스터에 구현되어 운영 클러스터에 추가 관리자 작업을 추가할 수 있다는 것입니다.

솔루션 **C**

솔루션 C에서는 아래 그림과 같이 NetApp SAN 볼륨을 HDFS 스토리지용 Hadoop 운영 클러스터에 직접 프로비저닝합니다.

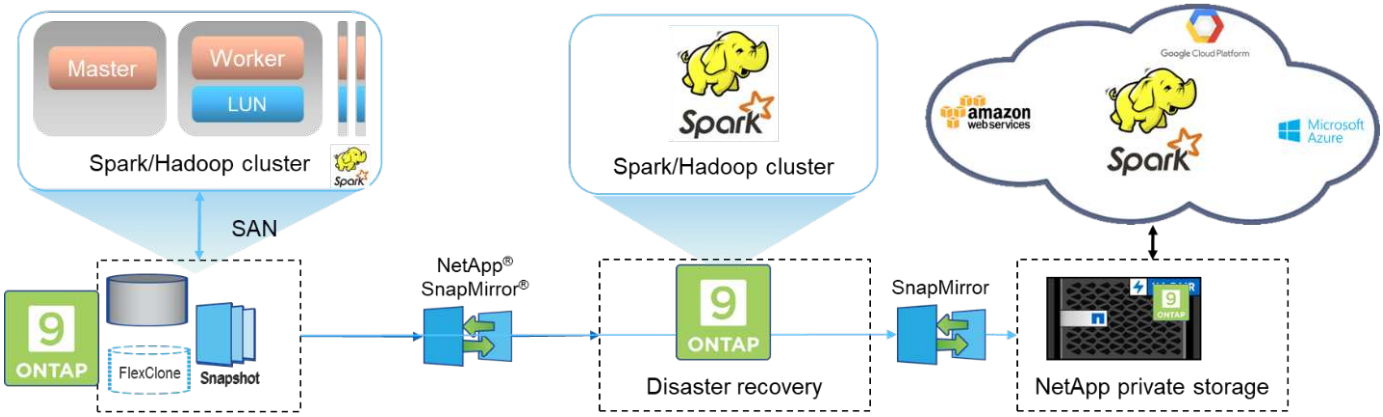

솔루션 C에 대한 자세한 단계는 다음과 같습니다.

- NetApp ONTAP SAN 스토리지는 HDFS 데이터 스토리지를 위한 운영 Hadoop 클러스터에서 프로비저닝됩니다.
- NetApp Snapshot 및 SnapMirror 기술은 운영 Hadoop 클러스터의 HDFS 데이터를 백업하는 데 사용됩니다.
- 백업이 스토리지 계층에 있기 때문에 스냅샷 복사본 백업 프로세스 중에 Hadoop/Spark 클러스터의 운영에 미치는 성능 영향은 없습니다.

> 스냅샷 기술은 데이터 크기에 관계없이 몇 초 내에 백업을 완료합니다.

솔루션 C의 이점은 다음과 같습니다.

- 스냅샷 기술을 사용하여 공간 효율적인 백업을 생성할 수 있습니다.
- NetApp 툴을 통해 엔터프라이즈 관리 기능을 지원합니다.

"다음: 사용 사례 2 - 클라우드에서 사내로 백업 및 재해 복구"

사용 사례 **2:** 클라우드에서 사내로 백업 및 재해 복구

"이전: 활용 사례 1 - Hadoop 데이터 백업"

이 사용 사례는 아래 그림과 같이 클라우드 기반 분석 데이터를 사내 데이터 센터에 백업해야 하는 브로드캐스트 고객을 기반으로 합니다.

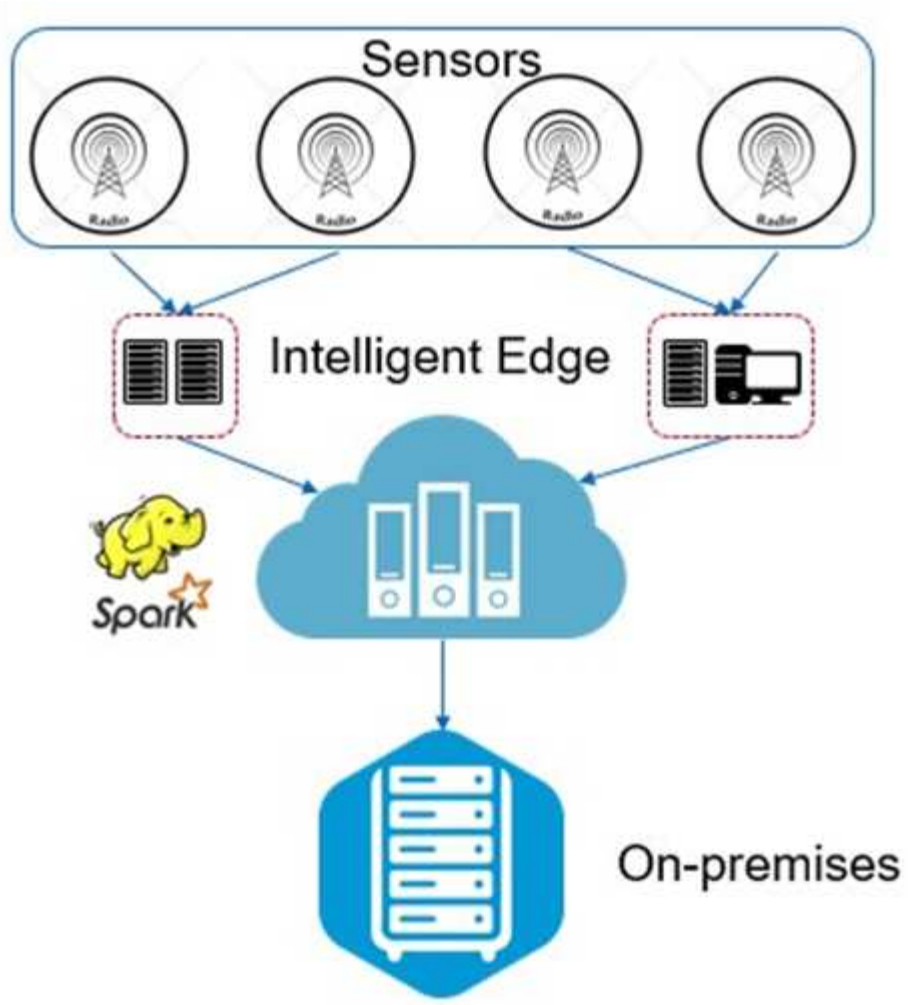

시나리오

이 시나리오에서는 IoT 센서 데이터가 클라우드로 수집되고 AWS 내의 오픈 소스 Apache Spark 클러스터를 사용하여 분석됩니다. 따라서 클라우드에서 처리된 데이터를 사내로 백업해야 합니다.

요구사항 및 당면 과제

이 사용 사례의 주요 요구사항과 과제는 다음과 같습니다.

- 데이터 보호를 사용하도록 설정하면 클라우드의 운영 Spark/Hadoop 클러스터에 성능 영향이 미치지 않습니다.
- 클라우드 센서 데이터를 효율적이고 안전한 방식으로 이동하고 사내로 보호해야 합니다.
- 온디맨드, 즉각적인, 낮은 클러스터 로드 시간 등 다양한 조건에서 데이터를 클라우드로 유연하게 전송할 수 있습니다.

해결 방법

이 고객은 Spark 클러스터 HDFS 스토리지에 AWS EBS(Elastic Block Store)를 사용하여 Kafka를 통해 원격 센서에서 데이터를 수신 및 수집했습니다. 따라서 HDFS 스토리지는 백업 데이터의 소스 역할을 합니다.

이러한 요구사항을 충족하기 위해 NetApp ONTAP Cloud를 AWS에 구축하고 NFS 공유를 생성하여 Spark/Hadoop 클러스터의 백업 타겟 역할을 수행합니다.

NFS 공유가 생성된 후 데이터 이동 없는 분석 모듈을 활용하여 HDFS EBS 스토리지에서 ONTAP NFS 공유로 데이터를 복제합니다. ONTAP 클라우드의 NFS에 데이터가 상주한 후에는 SnapMirror 기술을 사용하여 필요에 따라 클라우드에서 사내 스토리지로 데이터를 안전하고 효율적으로 미러링할 수 있습니다.

이 이미지는 클라우드에서 사내 솔루션으로 백업 및 재해 복구를 보여줍니다.

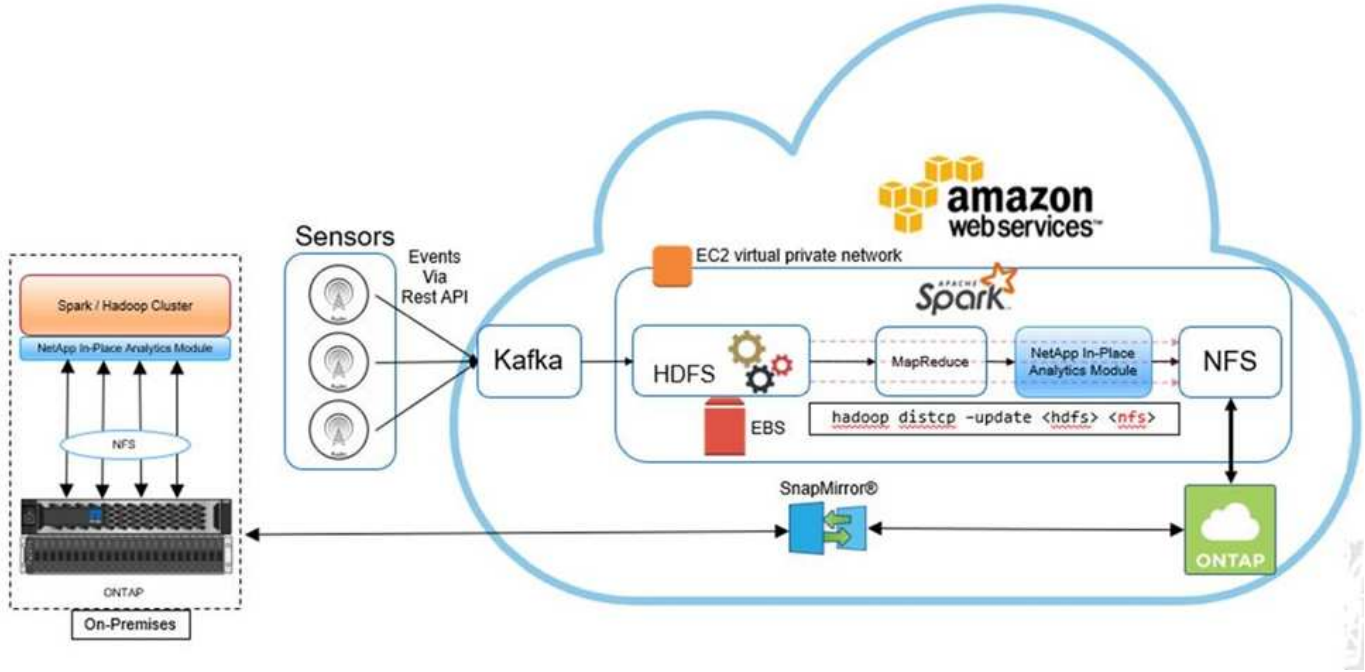

"다음: 사용 사례 3 - 기존 Hadoop 데이터에 대해 DevTest를 설정합니다."

사용 사례 3: 기존 Hadoop 데이터에 대해 DevTest 활성화

"이전: 사용 사례 2 - 클라우드에서 사내로 백업 및 재해 복구"

이 사용 사례에서 고객은 DevTest와 보고 목적으로 동일한 데이터 센터와 원격 위치에서 대량의 분석 데이터를 포함하는 기존 Hadoop 클러스터를 기반으로 새로운 Hadoop/Spark 클러스터를 신속하고 효율적으로 구축해야 합니다.

시나리오

이 시나리오에서는 사내 및 재해 복구 위치에 대규모 Hadoop 데이터 레이크를 구축하고 Spark/Hadoop 클러스터를 여러 개 구축했습니다.

요구사항 및 당면 과제

이 사용 사례의 주요 요구사항과 과제는 다음과 같습니다.

- DevTest, QA 또는 동일한 운영 데이터에 액세스해야 하는 기타 목적으로 여러 Hadoop 클러스터를 생성합니다. 여기서 문제는 매우 큰 Hadoop 클러스터를 공간 효율적인 방식으로 여러 번 즉시 클론 복제해야 한다는 것입니다.
- 운영 효율성을 위해 Hadoop 데이터를 DevTest 및 보고 팀에 동기화합니다.
- 운영 클러스터와 새 클러스터 간에 동일한 자격 증명을 사용하여 Hadoop 데이터를 배포합니다.
- 예약된 정책을 사용하여 운영 클러스터에 영향을 주지 않고 QA 클러스터를 효율적으로 생성합니다.

해결 방법

FlexClone 기술은 방금 설명한 요구 사항에 응답하는 데 사용됩니다. FlexClone 기술은 스냅샷 복사본의 읽기/쓰기 복사본입니다. 이 기능은 상위 스냅샷 복사본 데이터에서 데이터를 읽고 새 블록/수정된 블록에 대해 추가 공간만 사용합니다. 빠르고 공간 효율적입니다.

먼저, NetApp 일관성 그룹을 사용하여 기존 클러스터의 스냅샷 복사본을 생성했습니다.

NetApp System Manager 또는 스토리지 관리 프롬프트 내의 Snapshot 복사본 일관성 그룹 스냅샷 복사본은 애플리케이션 정합성이 보장된 그룹 스냅샷 복사본이며, FlexClone 볼륨은 일관성 그룹 스냅샷 복사본을 기반으로 생성됩니다. FlexClone 볼륨이 상위 볼륨의 NFS 엑스포트 정책을 상속한다는 점을 언급하는 것이 좋습니다. 스냅샷 복사본이 생성된 후에는 아래 그림과 같이 DevTest 및 보고를 위해 새 Hadoop 클러스터를 설치해야 합니다. In-Place Analytics Module은 NFS 데이터에 대한 In-Place Analytics Module 사용자 및 그룹 인증을 통해 새 Hadoop 클러스터에서 클론 생성된 NFS 볼륨에 액세스합니다.

적절한 액세스 권한을 가지려면 새 클러스터에 현재 위치 분석 모듈 사용자 및 그룹 구성에서 구성된 사용자에 대해 동일한 UID와 GUID가 있어야 합니다.

이 이미지는 DevTest용 Hadoop 클러스터를 보여 줍니다.

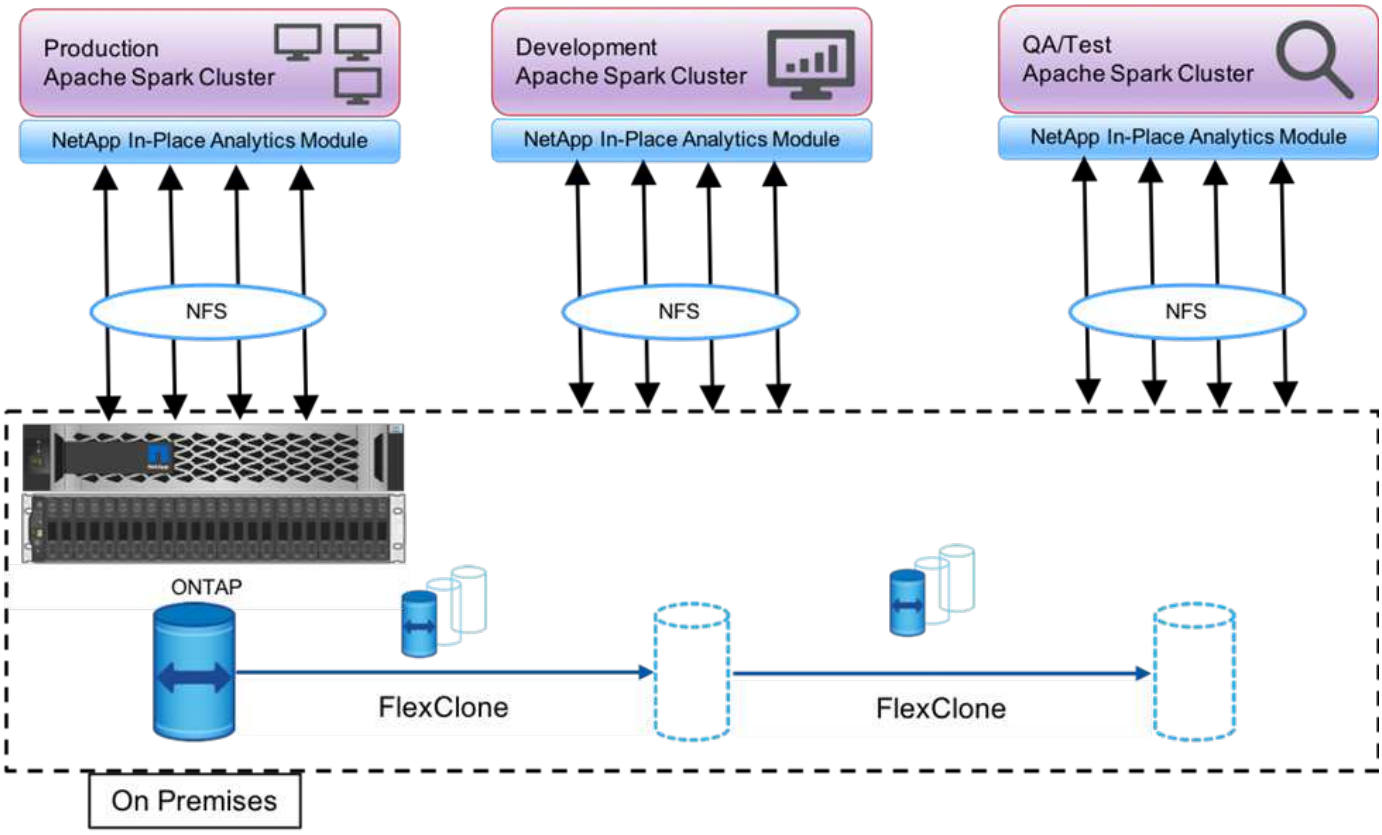

"다음: 사용 사례 4 - 데이터 보호 및 멀티 클라우드 연결"

사용 사례 4: 데이터 보호 및 멀티 클라우드 연결

"이전: 사용 사례 3 - 기존 Hadoop 데이터에 대해 DevTest 설정"

이 사용 사례는 고객의 빅데이터 분석 데이터를 위한 멀티 클라우드 연결을 제공하는 클라우드 서비스 파트너와 관련이 있습니다.

시나리오

이 시나리오에서는 여러 소스에서 AWS로 수신된 IoT 데이터가 NPS의 중앙 위치에 저장됩니다. NPS 스토리지는 AWS 및 Azure에 위치한 Spark/Hadoop 클러스터에 연결되므로, 여러 클라우드에서 실행되는 빅데이터 분석 애플리케이션이 동일한 데이터에 액세스할 수 있습니다.

요구사항 및 당면 과제

이 사용 사례의 주요 요구사항과 과제는 다음과 같습니다.

- 고객은 여러 클라우드를 사용하여 동일한 데이터에 대한 분석 작업을 실행하려고 합니다.
- 다양한 센서와 허브를 통해 사내, 클라우드와 같은 다양한 소스로부터 데이터를 받아야 합니다.
- 솔루션은 효율적이고 비용 효율적이어야 합니다.
- 주요 과제는 사내 및 다른 클라우드 간에 하이브리드 분석 서비스를 제공하는 비용 효율적이고 효율적인 솔루션을 구축하는 것입니다.

해결 방법

이 이미지는 데이터 보호 및 멀티 클라우드 연결 솔루션을 보여줍니다.

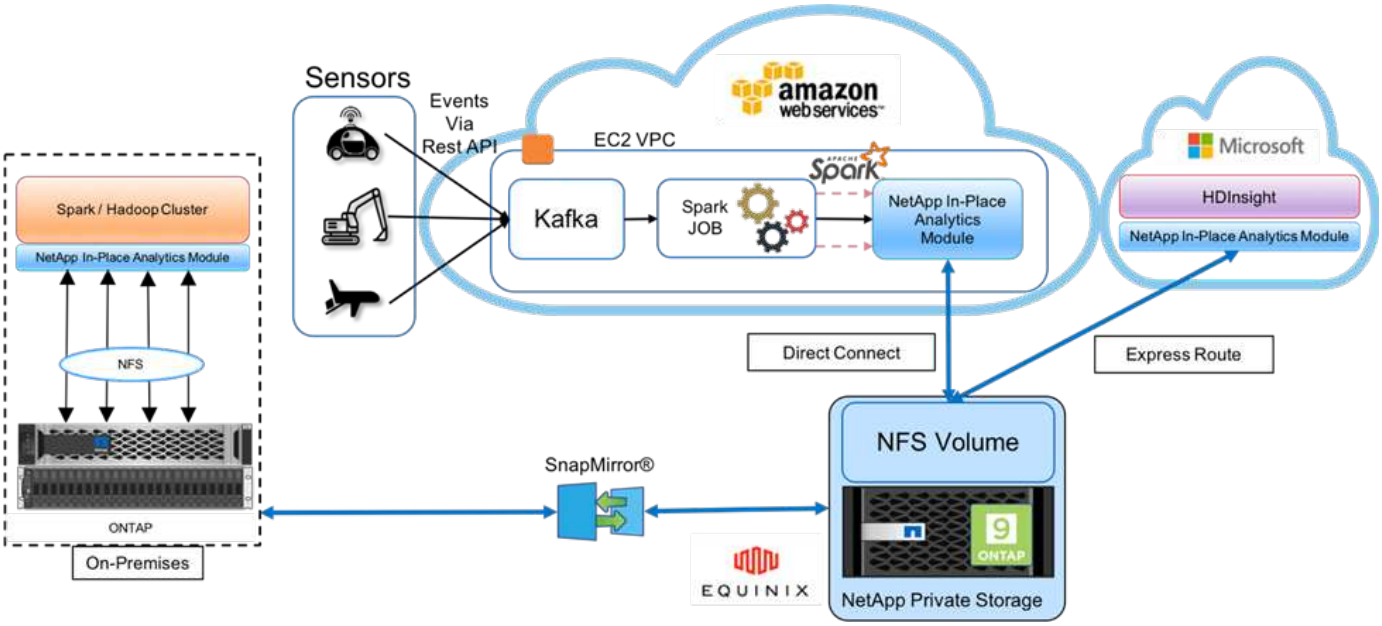

위 그림과 같이 센서의 데이터가 스트리밍되어 Kafka를 통해 AWS Spark 클러스터로 수집됩니다. 이 데이터는 Equinix 데이터 센터 내의 클라우드 공급자 외부에 있는 NPS에 있는 NFS 공유에 저장됩니다. NetApp NPS는 Direct Connect와 Express Route 연결을 통해 Amazon AWS 및 Microsoft Azure에 연결되므로, 고객은 데이터 이동 없는 분석 모듈을 활용하여 Amazon 및 AWS 분석 클러스터 모두에서 데이터에 액세스할 수 있습니다. 이 접근 방식은 여러 하이퍼 스케일러의 클라우드 분석 문제를 해결합니다.

따라서 사내 스토리지와 NPS 스토리지 모두 ONTAP 소프트웨어를 실행하므로 SnapMirror는 사내 클러스터에 NPS 데이터를 미러링하여 사내 및 여러 클라우드에 하이브리드 클라우드 분석을 제공할 수 있습니다.

최적의 성능을 위해 일반적으로 여러 네트워크 인터페이스 및 직접 연결/빠른 경로를 사용하여 클라우드 인스턴스에서 데이터에 액세스할 것을 권장합니다.

"다음: 사용 사례 5 - 분석 워크로드 가속화"

사용 사례 5: 분석 워크로드 가속화

"이전: 사용 사례 4 - 데이터 보호 및 멀티 클라우드 연결"

이 시나리오에서는 NetApp NFS 스토리지 솔루션을 사용하여 대형 금융 서비스 및 투자 은행의 분석 플랫폼을 현대화함으로써 자산 관리 및 정량적 사업부의 투자 위험 및 파생물 분석에 상당한 개선을 이루었습니다.

시나리오

고객의 기존 환경에서 분석 플랫폼에 사용되는 Hadoop 인프라는 Hadoop 서버의 내부 스토리지를 활용했습니다. JBOD 환경의 독점 특성으로 인해 조직 내의 많은 내부 고객은 실시간 데이터의 반복 샘플에 의존하는 시뮬레이션인 Monte Carlo 정량 모델을 활용할 수 없었습니다. 시장 이동이 불확실성의 영향을 이해하는 데 있어 최적화되지 않은 능력은 정량적 자산 관리 사업부에 비호의적으로 작용했습니다.

요구사항 및 당면 과제

이 은행의 정량적 사업부는 정확하고 시기 적절한 예측을 얻기 위한 효율적인 예측 방법을 원했습니다. 이를 위해 IT 팀에서는 인프라를 현대화하고, 기존 I/O 대기 시간을 줄이며, Hadoop, Spark와 같은 분석 애플리케이션의 성능을 개선하여 투자 모델을 효율적으로 시뮬레이션하고, 잠재적인 이익을 측정하고, 위험을 분석해야 한다는 사실을 깨달았습니다.

해결 방법

고객은 기존 Spark 솔루션에 대한 JBOD를 가지고 있었습니다. 그런 다음 NetApp ONTAP, NetApp StorageGRID 및 MinIO Gateway to NFS를 활용하여 잠재적인 이익과 위험을 평가하는 투자 모델에 대한 시뮬레이션 및 분석을 실행하는 금융 그룹의 정량적 대기 시간을 줄였습니다. 이 이미지는 NetApp 스토리지의 Spark 솔루션을 보여줍니다.

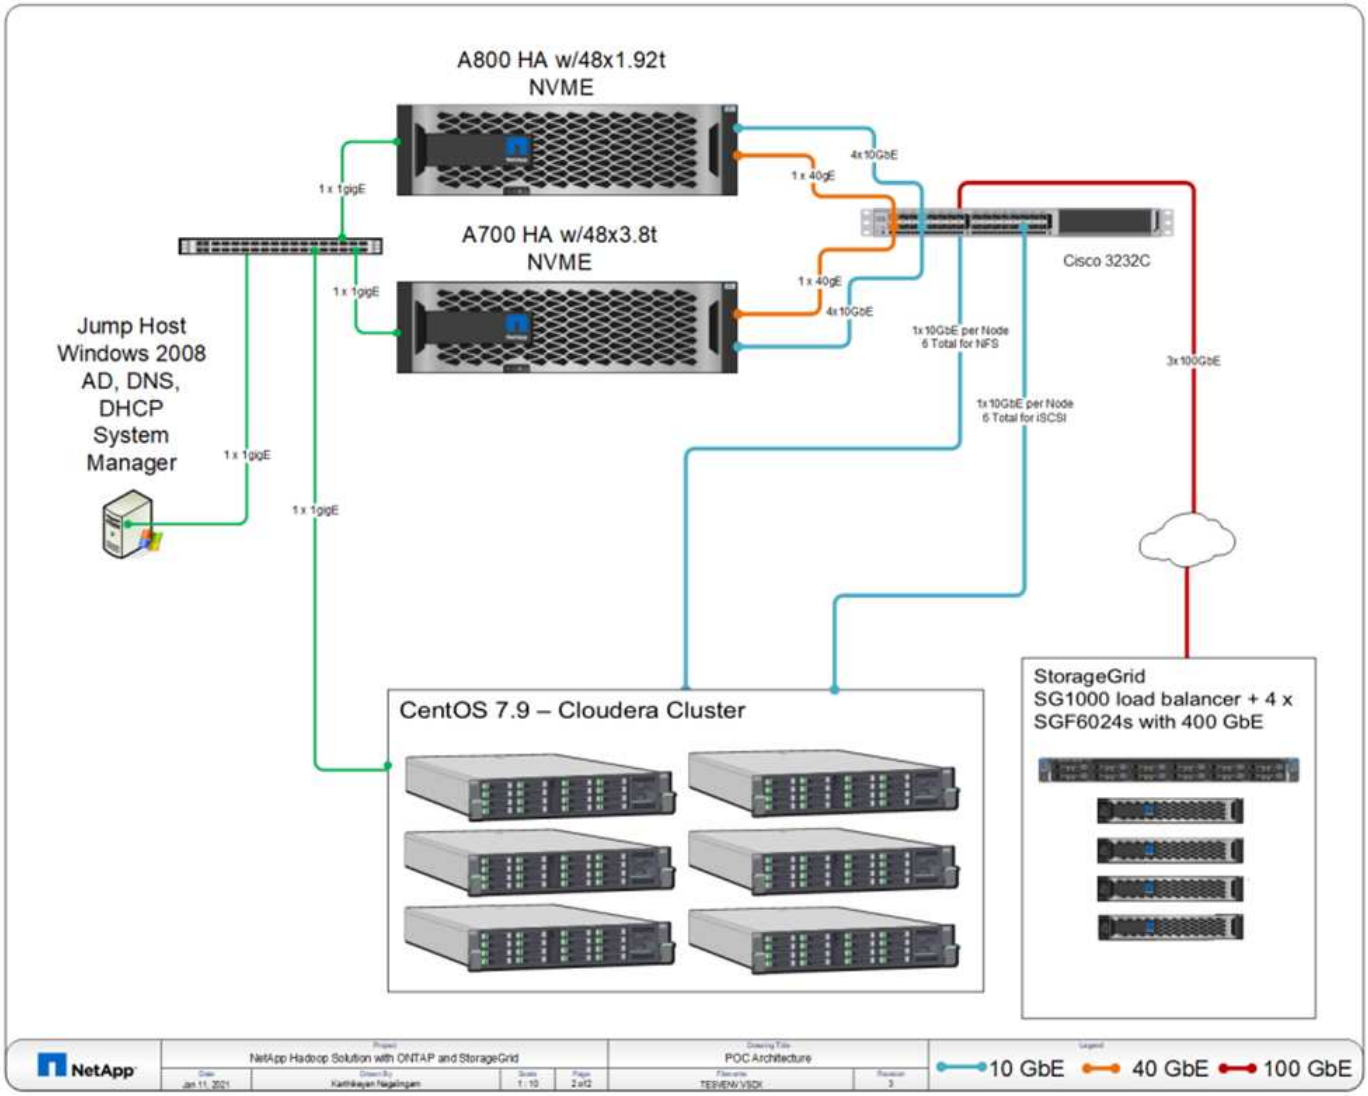

위 그림과 같이 StorageGRID A800, A700 시스템 및 AFF는 Spark가 있는 6노드 Hadoop 클러스터 및 데이터 분석 작업을 위한 YARN 및 Hive 메타데이터 서비스의 NFS 및 S3 프로토콜을 통해 쪽모이 세공 파일에 액세스하기 위해 구축되었습니다.

고객의 기존 환경에서 DAS(직접 연결 스토리지) 솔루션을 사용할 경우 컴퓨팅과 스토리지를 독립적으로 확장한다는 단점이 있었습니다. Spark용 NetApp ONTAP 솔루션을 통해 은행의 재무 분석 사업부에서 스토리지를 컴퓨팅에서 분리하여 필요에 따라 인프라 리소스를 보다 효율적으로 제공할 수 있게 되었습니다.

NFS와 함께 ONTAP를 사용함으로써 컴퓨팅 서버 CPU는 Spark SQL 작업에 거의 전적으로 활용되었고 I/O 대기 시간이 약 70% 감소되어 스파크 워크로드에 더 나은 컴퓨팅 성능과 성능 향상을 제공했습니다. 또한 CPU 활용률을 높임으로써 고객이 GPUDirect와 같은 GPU를 활용하여 플랫폼을 더욱 현대화할 수 있도록 했습니다. 또한 StorageGRID는 스파크 워크로드를 위한 저렴한 스토리지 옵션을 제공하며 MinIO 게이트웨이는 S3 프로토콜을 통해 NFS 데이터에 대한 안전한 액세스를 제공합니다. 클라우드의 데이터에 대해 NetApp은 Cloud Volumes ONTAP, Azure NetApp Files 및 NetApp Cloud Volumes Service를 권장합니다.

"다음: 결론."

결론

"이전: 사용 사례 5 - 분석 워크로드 가속화"

이 섹션에서는 다양한 Hadoop 데이터 보호 요구사항을 충족하기 위해 NetApp에서 제공하는 사용 사례 및 솔루션을 요약합니다. 고객은 NetApp이 제공하는 Data Fabric을 사용하여 다음을 수행할 수 있습니다.

- NetApp의 풍부한 데이터 관리 기능과 Hadoop 기본 워크플로우와의 통합을 활용하여 적합한 데이터 보호 솔루션을 유연하게 선택할 수 있습니다.
- Hadoop 클러스터의 백업 윈도우 시간을 약 70% 단축
- Hadoop 클러스터 백업으로 인한 성능 영향을 없앱니다.
- 여러 클라우드 공급자로부터 데이터 보호 및 데이터 액세스를 동시에 단일 분석 데이터 소스에 제공
- FlexClone ® 기술을 사용하여 빠르고 공간 효율적인 Hadoop 클러스터 복사본을 생성합니다.

추가 정보를 찾을 수 있는 위치

이 문서에 설명된 정보에 대한 자세한 내용은 다음 문서 및/또는 웹 사이트를 참조하십시오.

- NetApp 빅데이터 분석 솔루션

  "https://www.netapp.com/us/solutions/applications/big-data-analytics/index.aspx"

- NetApp 스토리지를 사용하는 Apache Spark 워크로드

  https://www.netapp.com/pdf.html?item=/media/26877-nva-1157-deploy.pdf

- Apache Spark용 NetApp 스토리지 솔루션

  "https://www.netapp.com/media/16864-tr-4570.pdf"

- NetApp에서 지원하는 Data Fabric 기반 Apache Hadoop

  "https://www.netapp.com/media/16877-tr-4529.pdf"

- NetApp 데이터 이동 없는 분석 모듈

  "https://library.netapp.com/ecm/ecm_download_file/ECMLP2854071"

감사의 말

- Paul Burland, 영업 담당자, ANZ Victoria District Sales, NetApp
- Hoseb Dermanilian, NetApp 비즈니스 개발 매니저
- Lee Dorrier, NetApp MPSG 이사
- David Thiessen, 시스템 엔지니어, ANZ Victoria District SE, NetApp

버전 기록

버전	날짜	문서 버전 기록
버전 1.0	2018년 1월	최초 릴리스

버전	날짜	문서 버전 기록
버전 2.0	2021년 10월	사용 사례 5로 업데이트: 분석 워크로드 가속화

저작권 정보

Copyright © 2022 NetApp, Inc. All rights reserved. 미국에서 인쇄됨 본 문서의 어떤 부분도 저작권 소유자의 사전 서면 승인 없이는 어떠한 형식이나 그래픽, 전자적 또는 기계적 수단(사진 복사, 레코딩 등)으로도 저작권 소유자의 사전 서면 승인 없이 전자 검색 시스템에 저장 또는 저장.

NetApp이 저작권을 가진 자료에 있는 소프트웨어에는 아래의 라이센스와 고지 사항이 적용됩니다.

본 소프트웨어는 NetApp에 의해 "있는 그대로" 제공되며 상품성 및 특정 목적에 대한 적합성에 대한 명시적 또는 묵시적 보증을 포함하여 이에 제한되지 않고, 어떠한 보증도 하지 않습니다. NetApp은 대체품 또는 대체 서비스의 조달, 사용 불능, 데이터 손실, 이익 손실, 또는 파생적 손해(소계 물품 또는 서비스의 조달, 사용 손실, 데이터 또는 수익 손실, 계약, 엄격한 책임 또는 불법 행위(과실 또는 그렇지 않은 경우)에 관계없이 어떠한 책임도 지지 않으며, 이는 이러한 손해의 가능성을 사전에 알고 있던 경우에도 마찬가지입니다.

NetApp은 본 문서에 설명된 제품을 언제든지 예고 없이 변경할 권리를 보유합니다. NetApp은 NetApp의 명시적인 서면 동의를 받은 경우를 제외하고 본 문서에 설명된 제품을 사용하여 발생하는 어떠한 문제에도 책임을 지지 않습니다. 본 제품의 사용 또는 구입의 경우 NetApp에서는 어떠한 특허권, 상표권 또는 기타 지적 재산권이 적용되는 라이센스도 제공하지 않습니다.

본 설명서에 설명된 제품은 하나 이상의 미국 특허 또는 해외 특허, 해외 특허, 해외 특허, 해외 특허, 해외 특허, 해외 특허, 해외 특허, 미국 출원 중인 특허로 보호됩니다.

권리 제한 표시: 정부에 의한 사용, 복제 또는 공개에는 DFARS 252.277-7103(1988년 10월) 및 FAR 52-227-19(1987년 6월)의 기술 데이터 및 컴퓨터 소프트웨어의 권리(Rights in Technical Data and Computer Software) 조항의 하위 조항 (c)(1)(ii)에 설명된 제한사항이 적용됩니다.

상표 정보

NETAPP, NETAPP 로고 및 에 나열된 마크는 NetApp에 있습니다 http://www.netapp.com/TM 는 NetApp, Inc.의 상표입니다. 기타 회사 및 제품 이름은 해당 소유자의 상표일 수 있습니다.